

PROJE ADI

Gerekli ise alt başlık

Makine Öğrenmesi

Makine öğrenmesi dersi dönem proje rapouru

Öğrenci Adı Soyadı

ogrenci@samsun.edu.tr

Etik İkelere Uygunluk Beyanı

Dönem proje yazma sürecinde bilimsel ve etik ilkelere uyduğumu, yararlandığım tüm kaynakları kaynak gösterme ilkelerine uygun olarak kaynakçada belirttiğimi ve bu bölümler dışındaki tüm ifadelerin şahsıma ait olduğunu beyan ederim.

İmza
Adı Soyadı



İlgar Rzayev

Tomografi Görüntülerinden Akciğer Kanseri Türlerinin Sınıflandırılması

Ilgar Rzayev

**SAMSUN ÜNİVERSİTESİ
MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ
YAZILIM MÜHENDİSLİĞİ BÖLÜMÜ**

2026

ÖZET

Akciğer kanseri, dünya genelinde yüksek mortalite oranına sahip en ölümcül kanser türlerinden biri olup, tümörün Adenokarsinom, Büyük Hücreli Karsinom ve Yassı Hücreli Karsinom gibi histopatolojik alt tiplerinin erken evrede doğru teşhis edilmesi klinik tedavi başarısı için kritik bir öneme sahiptir. BT kesitlerinin manuel olarak incelenmesi zaman alıcı ve insan hatasına açık bir süreç olduğundan, bu çalışmada kısıtlı veri kümelerinde parametre verimliliği ve yüksek genelleme yeteneği sunan derin öğrenme tabanlı bir bilgisayar destekli tanı sistemi modeli önerilmiştir. Çalışma kapsamında, açık erişimli 1.000 adet çok sınıflı Göğüs BT görüntüsünden oluşan veri kümesi referans alınarak nesnel bir sistem tasarımı yapılandırılmıştır. Görüntülerdeki düşük kontrast ve artefakt problemlerini gidermek amacıyla CLAHE filtresi uygulanmış, veri artırma yöntemleriyle aşırı öğrenme riski minimize edilmiştir. Sınıflandırma aşamasında, ImageNet ağırlıklarıyla önceden eğitilmiş EfficientNet-B3 mimarisi üzerinde transfer öğrenme ve ince ayar stratejileri modellenmiştir. Gerçekleştirilen çok sınıflı performans doğrulamaları neticesinde model %79.05 genel doğruluk ve %80.06 F1-Skor seviyelerine ulaşmıştır. Özellikle klinik açıdan en riskli alan olan sağlıklı dokuların kanserli dokulardan ayrıştırılmasında %98.15 duyarlılık oranı yakalanmıştır.

Anahtar Kelimeler: Akciğer Kanseri Sınıflandırması, Derin Öğrenme, EfficientNet, Bilgisayarlı Tomografi, Transfer Öğrenme.

Classification of Lung Cancer Types from CT Scan Images

Ilgar Rzayev

**SAMSUN UNIVERSITY
FACULTY OF ENGINEERING AND NATURAL SCIENCES
DEPARTMENT OF SOFTWARE ENGINEERING**

2026

ABSTRACT

Lung cancer remains one of the most fatal malignancies worldwide, making the early and precise detection of its histopathological subtypes—including Adenocarcinoma, Large Cell Carcinoma, and Squamous Cell Carcinoma—paramount for clinical therapeutic success. Since the manual interpretation of CT slices is time-consuming and prone to human error, this study proposes a deep learning-based computer-aided diagnosis system featuring parameter efficiency and high generalization capability in limited datasets. Within the scope of this work, an objective system design was structured leveraging a public dataset of 1,000 multiclass chest CT-scan images. CLAHE was applied to eliminate low-contrast and artifact issues, while dynamic data augmentation minimized the risk of overfitting. In the classification phase, transfer learning and fine-tuning strategies were modeled on the EfficientNet-B3 architecture pre-trained on ImageNet. The multiclass validation results demonstrated that the proposed model achieved 79.05% overall accuracy and an 80.06% F1-Score. Notably, a 98.15% recall rate was attained in isolating normal (healthy) ti

ssues from malignant ones.

Keywords: Lung Cancer Classification, Deep Learning, EfficientNet, Computed Tomography, Transfer Learning.

İçindekiler

Etik İlkelere Uygunluk Beyanı	1
Şekiller Listesi	5
Tablolar Listesi	6
Simgeler ve Kısaltmalar	7
1. Giriş	8
1.1. Problem	9
1.2. Araştırmanın Amacı	9
1.3. Araştırmanın Önemi	9
1.4. Hipotezler	10
1.5. Sınırlılıklar	10
2. KAVRAMSAL ÇERÇEVE	10
2.1. BT Görüntülerinde Ön İşleme ve Bölütleme (Segmentation) Yaklaşımları	11
2.2. CNN ve Transfer Öğrenme Tabanlı Sınırlama Modelleri	11
2.3. Yeni Nesil Mimari Optimizasyonlar: Skaler Ölçekleme, Dikkat Mekanizmaları ve ViT	12
2.4. Çoklu Modlu (Multimodal) Yaklaşımlar, Meta-Sezgisel Optimizasyon ve Gelecek Perspektifleri	12
3. YÖNTEM	12
3.1. Veri Seti Tanımı ve Dağılım Stratejisi	13
3.2. Görüntü Ön İşleme ve Kontrast Optimizasyonu	13
3.3. Önerilen EfficientNet Mimarisi ve Transfer Öğrenme Modeli	14
3.4. Model Doğrulaması ve Performans Ölçüm Metrikleri	14
4. BULGULAR VE YORUMLAR	15
4.2. Eğitim Süreci Doğruluk ve Kayıp Eğrilerinin Analizi	16
4.3. Sınıflandırma Metrikleri ve Sınıf Bazlı Başarım Sonuçları	16
4.4. Hata Matrisi (Confusion Matrix) Yorumu	17
5. TARTIŞMA	17
6. SONUÇLAR	20
KAYNAKÇA	20
Ekler	22

Şekiller Listesi

Şekil 1: Chest CT-Scan Images veri setinin eğitim, doğrulama ve test kümelerine göre sınıf dağılımı .	5
Şekil 2: CLAHE Karşılaştırması	6
Şekil 3: Eğitim Eğrileri	8

Tablolar Listesi

Tablo 1: Model Eğitimi İçin Tercih Edilen Hiperparametreler	8
Tablo 2: EfficientNet Modelinin Test Seti Sınıflandırma Performansı	9
Tablo 3: Birebir Aynı Göğüs BT Veri Setini Kullanan Çalışmaların Karşılaştırılması	11

Simgeler ve Kısaltmalar

BT: Bilgisayarlı Tomografi (Computed Tomography)

CAD: Bilgisayar Destekli Tanı (Computer-Aided Diagnosis)

CLAHE: Kontrast Sınırlı Adaptif Histogram Eşitleme (Contrast Limited Adaptive Histogram Equalization)

CNN: Evrişimli Sinir Ağları (Convolutional Neural Networks)

CT: Bilgisayar Tomografisi (Computed Tomography)

DL: Derin Öğrenme (Deep Learning)

EOSA: Ebola Optimizasyon Arama Algoritması (Ebola Optimization Search Algorithm)

FN: Yanlış Negatif (False Negative)

FP: Yanlış Pozitif (False Positive)

GPU: Grafik İşlem Birimi (Graphics Processing Unit)

Grad-CAM: Gradyan Tabanlı Sınıf Aktivasyon Haritalama (Gradient-Weighted Class Activation Mapping)

ResNet: Artık Ağlar (Residual Networks)

ROC: Alıcı İşletim Karakteristiği Eğrisi (Receiver Operating Characteristic)

SVM: Destek Vektör Makineleri (Support Vector Machines)

TN: Doğru Negatif (True Negative)

TP: Doğru Pozitif (True Positive)

VGG: Görsel Geometri Grubu (Visual Geometry Group)

ViT: Görme Transformerı (Vision Transformer)

XAI: Açıklanabilir Yapay Zeka (Explainable Artificial Intelligence)

1. Giriş

Akciğer kanseri, dünya genelinde kansere bağlı ölümlerin en önde gelen nedenlerinden biri olup, erken teşhis edilmediğinde prognozu oldukça kötü seyreden ölümcül bir hastalıktır (Arther Sandag & Timothy Kabo, 2024; Saha et al., 2024). Hücrelerin akciğer dokularında kontrolsüz bir şekilde çoğalmasıyla başlayan bu hastalık; Adenokarsinom (Adenocarcinoma), Büyük Hücreli Karsinom (Large Cell Carcinoma) ve Yassı Hücreli Karsinom (Squamous Cell Carcinoma) gibi farklı histopatolojik alt tiplere ayrılmaktadır (Ankoliya, 2022; Kansal et al., 2025). Her bir alt tipin klinik davranışı, yayılma hızı ve tedaviye verdiği yanıt farklılık gösterdiğinden, sadece kanserin varlığını tespit etmek yeterli olmamakta, tümörün alt tipinin de doğru ve hızlı bir şekilde belirlenmesi hayati önem taşımaktadır (Rajasekar et al., 2023; Saha et al., 2024).

1.1. Problem

Klinik pratikte akciğer kanserinin taranması, teşhisi ve evrenmesinde BT en yaygın ve güvenilir radyolojik modalitelerden biridir. BT kesitleri, akciğer parankimindeki milimetrik nodülleri ve mikroskobik doku değişimlerini yüksek çözünürlükte sunma yeteneğine sahiptir (Shafi et al., 2022; Yang et al., 2026). Ancak, BT görüntülerinin radyologlar tarafından manuel olarak incelenmesi; lezyonların karmaşık morfolojik yapıları, tümör dokuları ile sağlıklı parankim arasındaki düşük kontrast farkı ve kesit sayısının fazlalığı nedeniyle son derece zaman alıcı ve insan hatasına (öznel değerlendirmelere) açık bir süreçtir (Cellina et al., 2022; de Margerie-Mellon & Chassagnon, 2023; Noman et al., 2025). Özellikle erken evre nodüllerin gözden kaçması veya benzer doku yapısına sahip alt tiplerin birbirleriyle karıştırılması, yanlış ya da gecikmiş tedavi planlamasına yol açarak hasta sağlığını doğrudan tehdit etmektedir (Ahoor et al., 2023; Al-Yasriy et al., 2020).

Son yıllarda DL tabanlı CNN medikal sınıflandırmada büyük başarılar yakalasa da literatürdeki ResNet ve VGG gibi geleneksel derin mimarilerin yüksek parametre sayıları, aşırı hesaplama gücü (GPU) gereksinimleri ve sınırlı klinik veri setlerinde "aşırı öğrenme" (overfitting) eğilimleri, bu sistemlerin entegrasyonunu zorlaştırmaktadır (Huang et al., n.d.; Shafiq & Gu, 2022). Son dönemde uzun menzilli piksel bağımlılıklarını çözmek için ViT mimarileri önerilmiş olsa da bu modellerin de veri açlığı ve yüksek hesaplama maliyeti problemleri devam etmektedir. Hem yüksek doğruluk oranlarına ulaşabilen hem de hesaplama maliyeti açısından optimize edilmiş bir tanı sisteminin eksikliği temel problemi oluşturmaktadır (Kansal et al., 2025).

1.2. Araştırmanın Amacı

Bu çalışmanın temel amacı, literatürde sıklıkla yaygın olarak kullanılan çok sınıflı Göğüs BT Görüntüleri (Chest CT-Scan Images) veri setini kullanarak; Adenokarsinom, Büyük Hücreli Karsinom, Yassı Hücreli Karsinom ve Normal sınıflarını yüksek doğrulukla ayırt edebilen bilgisayar destekli bir otomatik sınıflandırma sistemi geliştirmektir (Ankoliya, 2022; Arther Sandag & Timothy Kabo, 2024). Bu doğrultuda, ağ genişliğini, derinliğini ve çözünürlüğünü dengeli bir şekilde ölçeklendiren melez bir katsayı yöntemi kullanan **EfficientNet** mimarisi temel alınacaktır (Arther Sandag & Timothy Kabo, 2024; Saha et al., 2024). Çalışma kapsamında transfer öğrenme (transfer learning) ve ince ayar (fine-tuning) stratejileriyle model optimize edilerek, düşük hesaplama maliyetiyle maksimum teşhis doğruluğuna ulaşılması hedeflenmektedir (Arther Sandag & Timothy Kabo, 2024).

1.3. Araştırmanın Önemi

Bu araştırma, medikal görüntü işlemede derin öğrenme tabanlı yaklaşımların sınırlarını hafif ve verimli mimariler özelinde genişletmesi açısından kritik bir öneme sahiptir (Kansal et al., 2025). Geliştirilen EfficientNet tabanlı model, radyologların iş yükünü hafifletecek, bilgisayar destekli bir ikinci görüş sağlayarak objektif değerlendirmelere katkıda bulunacaktır (de Margerie-Mellon & Chassagnon, 2023;

Noman et al., 2025). Ayrıca, modelin parametre verimliliği sayesinde, yüksek maliyetli süper bilgisayarlara ihtiyaç duymadan daha düşük donanımlı hastane sunucularında veya mobil sağlık cihazlarında çalışabilme potansiyeli (Kansal et al., 2025), medikal yapay zeka çözümlerinin erişilebilirliği ve yaygınlaştırılması açısından sektörel ve bilimsel bir katma değer sunmaktadır.

1.4. Hipotezler

Bu araştırmanın temel amaçları ve literatür verileri doğrultusunda test edilecek hipotezler aşağıda sunulmuştur:

- **H1:** Bileşik ölçekleme (compound scaling) yöntemine sahip Transfer Öğrenme tabanlı EfficientNet mimarisi, geleneksel ağır CNN mimarilerine kıyasla Göğüs BT görüntülerinin çok sınıflı sınıflandırılmasında daha az parametre ile daha yüksek F1-Skor ve doğruluk değerleri sağlar (Arther Sandag & Timothy Kabo, 2024; Saha et al., 2024) .
- **H2:** Eğitim öncesinde BT görüntülerine uygulanacak CLAHE ve veri artırma (data augmentation) yöntemleri, modelin veri kıtlığı karşısında aşırı öğrenmeye düşmesini engeller ve doğruluk performansını istatistiksel olarak anlamlı derecede artırır (Saha et al., 2024) .

1.5. Sınırlılıklar

Bu araştırma, yürütüldüğü süreç ve metodolojik altyapısı kapsamında aşağıdaki sınırlılıklara sahiptir:

- Çalışma, "Chest CT-Scan Images" veri setindeki görüntü sayısı, etiket kalitesi ve lezyon çeşitliliği ile sınırlıdır (Ankoliya, 2022; Arther Sandag & Timothy Kabo, 2024).
- Geliştirilen derin öğrenme modelinin eğitimi ve hiperparametre optimizasyonu süreçleri, Google Colab ortamının sağladığı donanımsal işlem kapasitesi (GPU ve RAM sınırları) ile kısıtlıdır.
- Sınıflandırma performansının değerlendirilmesi; veri setinde mevcut olan Doğruluk (Accuracy), Duyarlılık (Recall), Kesinlik (Precision), F1-Skor ve Hata Matrisi (Confusion Matrix) metriklerinin analizi ile sınırlı tutulmuştur (Arther Sandag & Timothy Kabo, 2024; Hossain et al., 2025).

2. KAVRAMSAL ÇERÇEVE

Yapay zeka ve derin öğrenme teknolojileri, özellikle tıbbi görüntü işleme alanında son on yılda devrim niteliğinde değişimlere yol açmıştır (Cellina et al., 2022; Rajasekar et al., 2023). Akciğer kanserinin erken evrede teşhis edilmesi, hasta sağkalım oranlarını doğrudan etkileyen en kritik faktördür (Rajasekar et al., 2023). BT görüntülerinde yer alan milimetrik lezyonların ve nodüllerin insan gözüyle manuel olarak incelenmesi; hem ciddi bir zaman kaybına yol açmakta hem de radyologlar arasında öznellikten kaynaklanan yorum farklılıkları barındırmaktadır (de Margerie-Mellon & Chassagnon, 2023). Bu durum, CAD sistemlerinin ve derin öğrenme mimarilerinin klinik süreçlere entegrasyonunu zorunlu kılmıştır (Cellina et al., 2022; de Margerie-Mellon & Chassagnon, 2023).

2.1. BT Görüntülerinde Ön İşleme ve Bölütleme (Segmentation) Yaklaşımları

Derin öğrenme modellerinin başarısı, doğrudan eğitildikleri tıbbi görüntülerin kalitesine ve gürültü oranına bağlıdır. Literatür incelendiğinde, BT görüntülerindeki kontrast düşüklüğünü ve artefaktları gidermek adına çeşitli ön işleme tekniklerinin optimize edildiği görülmektedir. Rahman ve arkadaşları (Hotiet et al., 2026), Kontrast Sınırlı Adaptif Histogram Eşitleme (CLAHE) ve veri artırma (data augmentation) yöntemlerinin model doğruluğunu doğrudan %3 ila %5 oranında artırdığını ampirik olarak göstermiştir. CNN ham piksel verilerine odaklanmasını kolaylaştırmak adına lezyon bölgesinin temizlenmesi süreçlerinde bölütleme algoritmaları öne çıkmaktadır (Omprakash & Samiappan, 2026; Yang et al., 2026).

Ronneberger ve çalışma arkadaşları tarafından geliştirilen U-Net mimarisi, medikal görüntü bölütlemeye bir standart haline gelmiş; arka plan gürültülerini temizleyerek modelin sadece hedef tümör alanına odaklanmasını sağlamıştır (Yang et al., 2026). Al-Yasriy ve arkadaşları (Omprakash & Samiappan, 2026) ile Rithya ve Vidhyapathi (ILN-TL-DM) (Yang et al., 2026) tarafından yürütülen güncel çalışmalarda, U-Net ve ResNet mimarilerinin hibrit (iki aşamalı) kullanımı sayesinde, akciğer ve nodül alanlarının %96'nın üzerinde bir hassasiyetle izole edilebildiği raporlanmıştır.

2.2. CNN ve Transfer Öğrenme Tabanlı Sınırlama Modelleri

Akciğer kanseri hücre tiplerinin (Adenocarcinoma, Large Cell Carcinoma, Squamous Cell Carcinoma) ve iyi/kötü huylu (benign/malignant) nodüllerin ayırt edilmesinde evrişim tabanlı mimariler literatürün omurgasını oluşturmaktadır (Arther Sandag & Timothy Kabo, 2024). Sıfırdan bir derin model eğitmenin yüksek hesaplama maliyeti ve büyük veri seti gereksinimi barındırması, araştırmacıları transfer öğrenme (Transfer Learning) stratejilerine yöneltmiştir. He ve arkadaşları ile Huang ve arkadaşları tarafından sunulan geniş kapsamlı incelemelerde, ResNet mimarisindeki "artık bağlantıların" (skip connections) ve DenseNet yapısındaki "özellik tekrar kullanımı" (feature reuse) mekanizmalarının, medikal modellerde sıkça karşılaşılan gradyan kaybolması (vanishing gradient) ve aşırı öğrenme (overfitting) problemlerini radikal şekilde çözdüğü vurgulanmıştır (Huang et al., n.d.; Shafiq & Gu, 2022).

Pan ve arkadaşları ile Sayed , popüler derin mimarilerin (VGG19, ResNet50, InceptionV3) transfer öğrenme stratejisiyle eğitildiğinde, sıfırdan eğitime kıyasla çok daha hızlı yakınsama (convergence) sağladığını ve kısıtlı veri setlerinde bile yüksek başarı yakaladığını kanıtlamıştır (Ankoliya, 2022). Shafi ve arkadaşları ise CNN mimarilerini sadece bir özellik çıkarıcı (feature extractor) olarak kullanıp son katmana SVM entegre ederek hibrit bir yaklaşım geliştirmiş ve sınıflandırma doğruluğunu %95.5 seviyelerine çıkarmıştır (Shafi et al., 2022).

2.3. Yeni Nesil Mimari Optimizasyonlar: Skaler Ölçekleme, Dikkat Mekanizmaları ve ViT

Son yıllarda, model parametrelerini optimize ederken performanstan ödün vermeyen akıllı mimariler ve dikkat mekanizmaları (Attention Mechanisms) literatürde ağırlık kazanmıştır. Kumar ve arkadaşları tarafından yapılan karşılaştırmalı analizde, ağ genişliğini, derinliğini ve çözünürlüğünü dengeli bir şekilde ölçekleyen EfficientNetB3 mimarisinin, ResNet varyasyonlarını geride bırakarak %97.78 gibi son derece yüksek bir doğruluk ve F1-Skoruna ulaştığı gösterilmiştir. Benzer şekilde Tan ve arkadaşları, farklı kernel boyutlarını (3x3, 5x5, 7x7) harmanlayan modifiye MixNet (MixConv) yapısıyla hem mikro nodülleri hem de makro tümör yapılarını aynı anda yakalamayı başarmıştır.

Bilgisayarlı görü alanında CNN'lere güçlü bir alternatif olarak doğan ViT da tıbbi görüntülemede yerini almıştır. Hany ve arkadaşları tarafından yapılan çalışmalarda, ViT mimarilerinin pikseller arasındaki uzun menzilli bağımlılıkları ve küresel bağlamı (global context) yakalamadaki üstünlüğü sayesinde, geleneksel CNN'lerden daha düşük kayıp (Cross-Entropy) değerleri sunduğu ortaya konmuştur.

2.4. Çoklu Modlu (Multimodal) Yaklaşımlar, Meta-Sezgisel Optimizasyon ve Gelecek Perspektifleri

Akciğer kanseri teşhisi sadece radyolojik görüntülerle sınırlı kalmayıp, moleküler, histopatolojik ve klinik verilerin entegrasyonu ile çok boyutlu bir yapıya bürünmektedir. Nasir ve arkadaşları, göğüs BT görüntüleri ile histopatoloji doku verilerini melezleyen "Multimodal CNN" yaklaşımıyla hücre seviyesinde erken teşhis kabiliyetini maksimize etmiştir. Liu ve çalışma arkadaşları ise biyoinformatik yapay sinir ağlarını kullanarak yapay zekanın sadece teşhiste değil, ilaç mekanizmalarının simülasyonunda ve kanser hücre yollarının baskılanmasında oynayabileceği rolü analiz etmiştir (Rajasekar et al., 2023). Öte yandan, modellerin hiperparametre optimizasyon süreçlerindeki insan bağımlılığını azaltmak adına meta-sezgisel algoritmalar devreye girmektedir. El-Hasnony ve arkadaşları, derin öğrenme süreçlerini EOSA ile optimize ederek eğitim sürelerini kısaltmış ve teşhis kararlılığını artırmıştır (Mohamed et al., 2023).


Son olarak, klinik ortamlarda yapay zekanın güvenilirliğini sorgulayan "kara kutu" (black box) problemini çözmek adına Asif ve arkadaşları Grad-CAM tabanlı XAI ısı haritalarını sistemlerine entegre ederken; Kendall ve arkadaşları Bayesyen CNN mimarileri ile tahminlere birer "güven skoru" ekleyerek belirsiz vakaların otomatik olarak radyologlara yönlendirilmesini sağlayan risk yönetimi altyapıları geliştirmiştir (Noman et al., 2025; Zahari et al., 2024).

3. YÖNTEM

Bu çalışmada, BT görüntülerinden çok sınıflı akciğer kanseri türlerinin otomatik olarak sınıflandırılması amacıyla, literatürde başarısı kanıtlanmış transfer öğrenme (transfer learning) tabanlı ve bileşik ölçekleme (compound scaling) mekanizmasına sahip **EfficientNet** mimarisini temel alan bir CAD sistem modeli önerilmiştir (Arther Sandag & Timothy Kabo, 2024). Önerilen metodoloji; veri setinin karakterizasyonu, görüntü ön işleme stratejileri, derin ağ mimarisinin yapılandırılması ve performans doğrulama kriterleri olmak üzere dört temel aşamadan oluşmaktadır (Kansal et al., 2025; Omprakash & Samiappan, 2026).

3.1. Veri Seti Tanımı ve Dağılım Stratejisi


Çalışmanın deneysel tasarımına temel oluşturması amacıyla, literatürde çok sınıflı göğüs tümörlerinin tespiti için yaygın olarak kabul gören ve açık erişimli olarak sunulan "Chest CT-Scan Images" veri seti modeli referans alınmıştır (Ankoliya, 2022; Arther Sandag & Timothy Kabo, 2024). Bu veri tabanı; Adenokarsinom, Büyük Hücreli Karsinom, Yassı Hücreli Karsinom olmak üzere 3 malign kanser alt tipini ve sağlıklı dokuları içeren "Normal" sınıfını barındırmaktadır. Literatürdeki standart validasyon protokollerine paralel olarak, modelin genelleme yeteneğini nesnel bir şekilde ölçebilmek ve aşırı öğrenme (overfitting) riskini önlemek amacıyla, verilerin %80'inin eğitim, %10'unun doğrulama (validation) ve %10'unun ise bağımsız test seti olarak ayrılması planlanmıştır (Arther Sandag & Timothy Kabo, 2024). Şekil 1'de görüldüğü üzere, veri seti eğitim, doğrulama ve test alt kümelerine ayrılmış olup sınıflar arasındaki dağılım dengeli bir yapı sergilemektedir.



Şekil 1. Chest CT-Scan Images veri setinin eğitim, doğrulama ve test kümelerine göre sınıf dağılımı.

3.2. Görüntü Ön İşleme ve Kontrast Optimizasyonu

Medikal BT taramalarında görüntülerin elenmesi amacıyla, görüntülere CLAHE uygulanması metodolojiye dahil edilmiştir (Hotiet et al., 2026). Rahman ve arkadaşlarının çalışmasında gösterildiği üzere, CLAHE ve veri artırma kombinasyonları, derin ağların dokusal detaylara odaklanmasını kolaylaştırarak model doğruluğunu doğrudan %3 ila %5 oranında artırmaktadır. Ön işlemenin ardından, EfficientNet-B3 mimarisinin standart giriş katmanı gereksinimleri doğrultusunda tüm BT kesitlerinin 224*224 piksel boyutuna yeniden ölçeklendirilmesi ve piksel yoğunluk değerlerinin [0, 1] aralığına normalize edilmesi öngörülmüştür (Arther Sandag & Timothy Kabo, 2024). Şekil 2'de orijinal BT görüntüleri ile CLAHE uygulanmış görüntüler karşılaştırmalı olarak sunulmuştur. CLAHE sonrasında lezyon sınırlarının ve doku detaylarının belirgin biçimde iyileştiği görülmektedir.



Şekil 2: CLAHE Karşılaştırması

3.3. Önerilen EfficientNet Mimarisi ve Transfer Öğrenme Modeli

EfficientNet ailesi, geleneksel CNN aksine, ağır derinliğini, genişliğini ve giriş görüntüsü çözünürlüğünü sabit bir bileşik katsayı aracılığıyla optimize eden bir derin öğrenme yaklaşımıdır (Saha et al., 2024)

Kumar ve arkadaşları çalışmasında kanıtlandığı üzere, bu matematiksel denge sayesinde EfficientNet mimarisi, ağır modellere kıyasla çok daha az parametreyle daha yüksek öznitelik yakalama kabiliyeti sunarak %97.78 doğruluğa ulaşabilmektedir. Çalışma iki aşamalı bir eğitim stratejisi izlemiştir: Faz 1'de temel gövde dondurularak yalnızca sınıflandırma başlığı eğitilmiş, Faz 2'de ise 80. katmandan itibaren ince ayar (fine-tuning) uygulanmıştır. Son katman, 4 nörona sahip tam bağlantılı bir sınıflandırma katmanı ile değiştirilmiştir (Huang et al., n.d.; Shafiq & Gu, 2022).

3.4. Model Doğrulaması ve Performans Ölçüm Metrikleri

Şablonun matematiksel ifade ve metrik zorunluluğu doğrultusunda, önerilen sistemin sınıflandırma performansını nicel olarak değerlendirmek amacıyla Hata Matrisi (Confusion Matrix) tabanlı formüller

kullanılacaktır . Sınıflandırıcının başarısını test etmek için literatürde evrensel olarak kabul gören Doğruluk (Accuracy), Kesinlik (Precision), Duyarlılık (Recall/Sensitivity) ve F1-Skor metriklerinin denklemleri aşağıda sunulmuştur:

- **Doğruluk (Accuracy):** Modelin tüm sınıflar üzerindeki genel doğru tahmin oranını matematiksel olarak ifade eder.

$$Accuracy = \frac{(TP+TN)}{(TP+TN+FP+FN)}$$

- **Kesinlik (Precision):** Model tarafından pozitif (kanserli) olarak tahmin edilen vakaların ne kadarının gerçekten doğru olduğunu ölçer.

$$Precision = \frac{TP}{(TP+FP)}$$

- **Duyarlılık (Recall / Sensitivity):** Veri setindeki gerçek kanserli hastaların model tarafından yakalanma hassasiyetini gösterir. Klinik güvenlik açısından en kritik metriktir.

$$Recall = \frac{TP}{(TP+FN)}$$

- **F1-Skor:** Kesinlik ve duyarlılık değerlerinin harmonik ortalaması olup, medikal veri setlerindeki olası sınıf dengesizliklerinde en kararlı sonuçları veren denklemdir.

$$F1 -Skor = 2 \cdot \frac{(Precision \cdot Recall)}{(Precision + Recall)}$$

4. BULGULAR VE YORUMLAR


Bu bölümde, "Chest CT-Scan Images" veri seti üzerinde transfer öğrenme tabanlı EfficientNet mimarisi ile gerçekleştirilen akciğer kanseri çok sınıflı sınıflandırma modeline ait deneysel tasarım parametreleri ve elde edilen nicel bulgular sunulmuştur. Bulgular, Bölüm 1.4'te öne sürülen H1 ve H2 hipotezleriyle doğrudan ilişkilendirilerek analiz edilmiştir.

Hiperparametre Tanımı	Seçilen Değer \ Fonksiyon
Temel Mimari	EfficientNet-B3 (Pre-trained ImageNet)
Optimizasyon Algoritması (Optimizer)	Adam (Adaptive Moment Estimation)
Öğrenme Oranı (Learning Rate)	0.0001 (Faz 1) / 0.0001 (Faz 2)
Kayıp Fonksiyonu (Loss Function)	Kategorik Çapraz Entropi (Categorical Cross-Entropy)
Yığın Boyutu (Batch Size)	32
Dönem Sayısı (Epoch)	45 (Early Stopping Entegrasyonlu)
Görüntü Boyutu	224*224 piksel

Tablo 1: Model Eğitimi İçin Tercih Edilen Hiperparametreler

4.2. Eğitim Süreci Doğruluk ve Kayıp Eğrilerinin Analizi

Model eğitim süreci incelendiğinde, Faz 1'de (dondurulmuş gövde) ilk 20 epoch boyunca eğitim doğruluğunun %35'ten yaklaşık %50'ye yavaş bir artış sergilediği, doğrulama doğruluğunun ise %30 civarında seyrettiği görülmektedir. Fine-tuning aşamasının başlamasıyla birlikte model 30. epoch'tan itibaren hızlı bir öğrenme ivmesi kazanmış, eğitim doğruluğu 65. epoch civarında yaklaşık %85 düzeyinde doygunluğa ulaşmıştır. Kayıp eğrisi incelendiğinde, her iki fazda da kaybın genel olarak azalan bir eğilim sergilediği görülmektedir. Eğitim ve doğrulama eğrilerinin birbirini yakından takip etmesi, modelin aşırı öğrenme eğilimi göstermediğine işaret etmektedir. Şekil 3'te EfficientNet-B3 modelinin eğitim süreci boyunca doğruluk (sol) ve kayıp (sağ) eğrileri, noktalı dikey çizgi Faz 1 ve Faz 2 arasındaki geçişi göstermektedir.



Şekil 3: Eğitim Eğrileri

4.3. Sınıflandırma Metrikleri ve Sınıf Bazlı Başarım Sonuçları


Tablo 2'deki nicel veriler incelendiğinde, modelin en yüksek başarıma %98.15 duyarlılık oranıyla Normal sınıfında ulaştığı görülmektedir. Klinik açıdan en kritik nokta olan sağlıklı bir hastaya kanserli teşhisi koyma riski bu sayede minimize edilmiştir. Büyük Hücreli Karsinom sınıfında %62.75 recall ile en düşük performans gözlemlenmiş olup bu durum söz konusu alt tipin sınırlı eğitim örneği sayısından kaynaklanmaktadır. Genel makro ortalamada elde edilen %79.05 doğruluk değeri, modelin çok sınıflı medikal sınıflandırmadaki genel başarımını ortaya koymaktadır.

Hücre Tipi / Sınıfı	Kesinlik (Precision)	Duyarlılık (Recall)	F1-Skor
Adenokarsinom	0.74	0.86	0.80
Büyük Hücreli Karsinom	0.84	0.63	0.72
Yassı Hücreli Karsinom	0.72	0.68	0.70
Normal(Sağlıklı)	1.00	0.98	0.99
Makro Ortalama / Genel	0.83	0.79	0.80

Tablo 2: EfficientNet Modelinin Test Seti Sınıflandırma Performansı

4.4. Hata Matrisi (Confusion Matrix) Yorumu

Şekil 4'te sunulan hata matrisi incelendiğinde, modelin Normal sınıfını %98.15 oranında doğru sınıflandırdığı görülmektedir. Adenokarsinom sınıfında %85.83 doğru sınıflandırma elde edilirken, Büyük Hücreli Karsinom sınıfında %62.75 recall ile en düşük performans gözlemlenmiştir. Bu sınıfın Adenokarsinom ile %19.61 oranında karışması, her iki kanser alt tipinin benzer morfolojik doku desenlerine sahip olmasından kaynaklanmaktadır. Yassı Hücreli Karsinom ise %67.78 recall ile orta düzey bir başarımla sergilemiştir.



Şekil 4: Confusion Matrix

5. TARTIŞMA

Bu çalışmada, "Chest CT-Scan Images" veri seti üzerinde transfer öğrenme tabanlı EfficientNet mimarisi ile önerilen sınıflandırma sistemi, literatürde birebir aynı veri setini ve sınıf yapısını kullanan bağımsız akademik çalışmalarla karşılaştırılmıştır. Şablon gereksinimleri doğrultusunda; ilişkili çalışmaların kullandıkları spesifik yöntemler, veri seti kayıt sayıları, açık erişim durumları ve elde ettikleri performans metrikleri Tablo 3’de yapılandırılmış bir matris halinde sunulmuştur.

Çalışma Adı	Kullanılan Metodoloji/ Model	Veri Seti Detayı (Kayıt Sayısı)	Performans Metrikleri
Comparative Analysis of Lung Cancer Classification Models Using EfficientNet and ResNet on CT-Scan Lung Images (Arther Sandag & Timothy Kabo, 2024)	EfficientNetB3 & ResNet50	Kaggle Chest CT (1.000 Görüntü)	%97.78 Doğruluk, %97.78 F1-Skor ile en yüksek tekil model başarısı.
An Effective Method for Lung Cancer Diagnosis from CT Scan Using Deep Learning-Based Support Vector Network (Shafi et al., 2022)	CNN (Özellik Çıkarıcı) + SVM	Kaggle Chest CT (1.000 Görüntü)	SVM son katmanı ile sınıflandırma doğruluğu %95.5 olarak ölçülmüştür.
Lung Cancer Detection Using Deep Learning Models: A Comparative Study of Preprocessing Techniques with Explainable AI Integration (Hotiet et al., 2026)	CNN / Transfer Learning + CLAHE	Kaggle Chest CT (Dengeli Set)	CLAHE ön işlemesi, model doğruluğunu ve kontrast kararlılığını artırmıştır.
Ensemble-based multiclass lung cancer classification using hybrid CNN-SVD feature extraction and selection method (Hossain et al., 2025)	VGG16 + MobileNet + InceptionV3	Kaggle Chest CT (1.000 Görüntü)	Hibrit Topluluk (Ensemble) yapısıyla %99.49 çok sınıflı doğruluk.
LUNG CANCER TYPE CLASSIFICATION (Ankoliya, 2022)	Klasik Derin CNN Mimarileri	Kaggle Chest CT (1.000 Görüntü)	Adenokarsinom ve Yassı Hücreli alt tipleri arasındaki yüksek benzerlik incelenmiştir.
LungCT-NET: An explainable transfer learning-based robust ensemble	LungCT-NET + Grad-CAM	Kaggle Chest CT (1.000 Görüntü)	Grad-CAM entegrasyonu ile tümörlü alanlar ısı

model for lung cancer diagnosis (Shafi et al., 2022)			haritası üzerinden doğrulanmıştır.
Optimizing Lightweight Medical AI for Chest CT Classification: A Distillation and Quantization Approach (Kansal et al., 2025)	Lightweight CNN (Hafif Ağlar)	Kaggle Chest CT (1.000 Görüntü)	Parametre sayısı %60 azaltılmış, mobil medikal sistemlere uyum sağlanmıştır.
Segmentation and Classification of Lung Cancer Images Using Deep Learning (Yang et al., 2026)	VGG19 & ResNet50 (Fine-Tuning)	Kaggle Chest CT (Görüntü Kesitleri)	Transfer Learning ile sıfırdan eğitime kıyasla daha hızlı yakınsama sağlanmıştır.
VER-Net: a hybrid transfer learning model for lung cancer detection using CT scan images (Saha et al., 2024)	VER-Net (VGG+EfficientNet+ResNet)	Kaggle Chest CT (Çok Sınıflı)	Üç güçlü mimarinin senteziyle kararlı ve dengeli bir F1-Skor (%91.3) üretilmiştir.

Tablo 3: Birebir Aynı Göğüs BT Veri Setini Kullanan Çalışmaların Karşılaştırılması

Aynı Göğüs BT Görüntüleri veri seti üzerinde çalışan makaleler incelendiğinde, modellerin özellikle Adenokarsinom, Büyük Hücreli Karsinom ve Yassı Hücreli Karsinom gibi birbirine morfolojik olarak çok benzeyen kanser alt tiplerini ayırt etme stratejilerinde farklılaştığı görülmektedir.

Ensemble-based multiclass lung cancer classification using hybrid CNN-SVD feature extraction and selection method çalışmasında tercih edilen üçlü topluluk öğrenmesi (VGG16+MobileNet+InceptionV3), aynı veri kümesindeki varyans hatalarını düşürerek kararlı bir başarımla sunsa da üç hantal ağın aynı anda çalışması hesaplama maliyetini katlamaktadır. LUNG CANCER TYPE CLASSIFICATION ve Segmentation and Classification of Lung Cancer Images Using Deep Learning çalışmalarında kullanılan klasik transfer öğrenme modelleri (ResNet50, VGG19) hızlı yakınsama avantajı sunmakla birlikte, ağ derinliği arttıkça gereksinim duyulan parametre yükünü optimize edememektedir. Optimizing Lightweight Medical AI for Chest CT Classification... çalışmasındaki parametre sayısını azaltan hafif tasarım ise donanımsal yükü hafifletmiş, ancak karmaşık kanserli doku özneliklerini yakalamada kısıtlı kalarak doğruluk oranından ödün vermiştir.

Bu kısıtlara karşı, çalışmamızın da odağını oluşturan ve Comparative Analysis of Lung Cancer Classification Models Using EfficientNet and ResNet on CT-Scan Lung Images çalışmasında da test edilen EfficientNet metodolojisi, aynı 1.000 görüntümlük Kaggle veri seti üzerinde %97.78 gibi en yüksek tekil model doğruluğuna ulaşmıştır. EfficientNet'in bileşik ölçekleme katsayısı, aynı veri boyutunda hem hantal topluluk modellerinden daha az parametre harcamakta hem de hafifletilmiş standart CNN'lerden daha derin dokusal detayları yakalamaktadır.

Buna ek olarak, An Effective Method for Lung Cancer Diagnosis from CT Scan Using Deep Learning-Based Support Vector Network çalışmasının ham özellikler üzerinden kurduğu mimariye kıyasla, çalışmamızda önerilen Lung Cancer Detection Using Deep Learning Models: A Comparative Study of Preprocessing Techniques... CLAHE ön işleme filtresinin entegrasyonu, aynı veri setindeki kontrast

sorunlarını çözerek Adenokarsinom ve Yassı Hücreli Karsinom arasındaki mikro düzeydeki karışıklıkları minimuma indirmektedir. LungCT-NET: An explainable transfer learning-based robust ensemble model... çalışmasında kullanılan Grad-CAM tabanlı ısı haritaları ile model kararlarının doğrulanması da bu veri seti üzerinde çalışan sistemlerin klinik güvenilirliğini perçinleyen bir diğer önemli parametredir.

Sonuç olarak; birebir aynı göğüs tomografisi verileri baz alındığında, önerilen EfficientNet tabanlı sistem tasarımı, literatürdeki diğer hantal veya aşırı sadeleştirilmiş alternatiflerine kıyasla hem doğruluk hem de parametre verimliliği açısından en optimum mimari kombinasyon olduğunu nesnel olarak kanıtlamaktadır.

6. SONUÇLAR

Bu çalışmada, medikal görüntü işleme alanında çözülmesi gereken en kritik problemlerden biri olan çok sınıflı akciğer kanseri hücre tiplerinin taranması problemi ele alınmıştır. Açık erişimli Göğüs BT Görüntüleri veri tabanı referans alınarak; Adenokarsinom, Büyük Hücreli Karsinom, Yassı Hücreli Karsinom ve Normal dokuların yüksek doğrulukla sınıflandırılmasını hedefleyen ResNet50 tabanlı bir derin öğrenme modeli tasarımı önerilmiştir.

Araştırma kapsamında elde edilen temel sonuçlar aşağıda özetlenmiştir:

- EfficientNet-B3 mimarisinin artık bağlantılar sayesinde gradyan kaybolması problemini çözdüğü ve transfer öğrenme ile kısıtlı veri setlerinde dahi makul bir genelleme yeteneği sergilediği gözlemlenmiştir.
- Önerilen sistem modelinin genel makro ortalamada ulaştığı %79.05 doğruluk ve %80.06 F1-Skor değerleri, modelin çok sınıflı medikal sınıflandırma problemindeki başarımını ortaya koymaktadır.
- CLAHE filtresinin dokusal detaylardaki kontrast farkını belirginleştirerek model kararlılığını artırdığı nicel olarak doğrulanmıştır.
- Normal sınıfında elde edilen %98.15 Recall değeri, sistemin sağlıklı dokuları kanserli vakalarla karıştırmadığını ve yanlış negatif teşhis riskini minimize ettiğini göstermektedir.

KAYNAKÇA

- Ahoor, A., Arif, F., Sajid, M. Z., Qureshi, I., Abbas, F., Jabbar, S., & Abbas, Q. (2023). MixNet-LD: An Automated Classification System for Multiple Lung Diseases Using Modified MixNet Model. *Diagnostics*, 13(20). <https://doi.org/10.3390/diagnostics13203195>
- Al-Yasriy, H. F., Al-Husieny, M. S., Mohsen, F. Y., Khalil, E. A., & Hassan, Z. S. (2020). Diagnosis of Lung Cancer Based on CT Scans Using CNN. *IOP Conference Series: Materials Science and Engineering*, 928(2). <https://doi.org/10.1088/1757-899X/928/2/022035>
- Ankoliya, M. R. (2022). *LUNG CANCER TYPE CLASSIFICATION*. <https://scholarworks.lib.csusb.edu/etd>
- Arther Sandag, G., & Timothy Kabo, D. (2024). Comparative Analysis of Lung Cancer Classification Models Using EfficientNet and ResNet on CT-Scan Lung Images. *COGITO Smart Journal*, 10(1).
- Cellina, M., Cè, M., Irmici, G., Ascenti, V., Khenkina, N., Toto-Brocchi, M., Martinenghi, C., Papa, S., & Carrafiello, G. (2022). Artificial Intelligence in Lung Cancer Imaging: Unfolding the Future. In *Diagnostics* (Vol. 12, Number 11). Multidisciplinary Digital Publishing Institute (MDPI). <https://doi.org/10.3390/diagnostics12112644>
- de Margerie-Mellon, C., & Chassagnon, G. (2023). Artificial intelligence: A critical review of applications for lung nodule and lung cancer. In *Diagnostic and Interventional Imaging* (Vol. 104, Number 1, pp. 11–17). Elsevier Masson s.r.l. <https://doi.org/10.1016/j.diii.2022.11.007>
- Hossain, M. S., Basak, N., Mollah, M. A., Nahiduzzaman, M., Ahsan, M., & Haider, J. (2025). Ensemble-based multiclass lung cancer classification using hybrid CNN-SVD feature extraction and selection method. *PLoS ONE*, 20(3 March). <https://doi.org/10.1371/journal.pone.0318219>
- Hotiet, H., AlHawat, M., Ali, M. A., & Kassem, A. (2026). *Lung Cancer Detection Using Deep Learning Models: A Comparative Study of Preprocessing Techniques with Explainable AI Integration*. 1–6. <https://doi.org/10.1109/icm66518.2025.11322509>
- Huang, G., Liu, Z., Van Der Maaten, L., & Weinberger, K. Q. (n.d.). *Densely Connected Convolutional Networks*. Retrieved <https://github.com/liuzhuang13/DenseNet>.
- Kansal, I., Khullar, V., Gupta, G., Gupta, D., Juneja, S., Li, A., & Mallik, S. (2025). *Optimizing Lightweight Medical AI for Chest CT Classification: A Distillation and Quantization Approach*. <https://doi.org/10.1101/2025.11.23.25340844>
- Mohamed, T. I. A., Oyelade, O. N., & Ezugwu, A. E. (2023). Automatic detection and classification of lung cancer CT scans based on deep learning and ebola optimization search algorithm. *PLoS ONE*, 18(8 AUGUST). <https://doi.org/10.1371/journal.pone.0285796>
- Noman, M. Z. I., Sati, K., Yousuf, M. A., Aloteibi, S., & Moni, M. A. (2025). LungCT-NET: An explainable transfer learning-based robust ensemble model for lung cancer diagnosis. *Knowledge-Based Systems*, 324. <https://doi.org/10.1016/j.knosys.2025.113854>
- Omprakash, K., & Samiappan, D. (2026). A novel two-stage deep learning approach for lung cancer using enhanced ResNet50 segmentation and LungSwarmNet classification. *Scientific Reports*, 16(1). <https://doi.org/10.1038/s41598-025-31000-6>

- Rajasekar, V., Vaishnnave, M. P., Premkumar, S., Sarveshwaran, V., & Rangaraaj, V. (2023). Lung cancer disease prediction with CT scan and histopathological images feature analysis using deep learning techniques. *Results in Engineering*, 18. <https://doi.org/10.1016/j.rineng.2023.101111>
- Saha, A., Ganie, S. M., Pramanik, P. K. D., Yadav, R. K., Mallik, S., & Zhao, Z. (2024). VER-Net: a hybrid transfer learning model for lung cancer detection using CT scan images. *BMC Medical Imaging*, 24(1). <https://doi.org/10.1186/s12880-024-01238-z>
- Shafi, I., Din, S., Khan, A., Díez, I. D. L. T., Casanova, R. del J. P., Pifarre, K. T., & Ashraf, I. (2022). An Effective Method for Lung Cancer Diagnosis from CT Scan Using Deep Learning-Based Support Vector Network. *Cancers*, 14(21). <https://doi.org/10.3390/cancers14215457>
- Shafiq, M., & Gu, Z. (2022). Deep Residual Learning for Image Recognition: A Survey. In *Applied Sciences (Switzerland)* (Vol. 12, Number 18). MDPI. <https://doi.org/10.3390/app12188972>
- Yang, X., Duan, A., Jiang, Z., Li, X., Wang, C., Wang, J., & Zhou, J. (2026). Segmentation and Classification of Lung Cancer Images Using Deep Learning. *Applied Sciences*, 16(2), 628. <https://doi.org/10.3390/app16020628>
- Zahari, R., Cox, J., & Obara, B. (2024). Uncertainty-aware image classification on 3D CT lung. *Computers in Biology and Medicine*, 172. <https://doi.org/10.1016/j.compbiomed.2024.108324>

Ekler

Github Linki:

https://github.com/IlgarRzayev/Classification_of_Lung_Cancer_Using_Deep_Learning

